

10.000 entregas. 1 padrão.

FLÓRIDA CENTRAL, 2023 — 15% DE MISSING RATE

Sistema end-to-end de detecção de fraudes em entregas Walmart com ML não supervisionado, score de risco multi-fator e dashboard analítico de **9 módulos em produção**.

Python

scikit-learn

MLflow

Streamlit

PostgreSQL

Isolation Forest

K-Means

O custo invisível no e-commerce


Em 2023, o Walmart registrou **\$6,5 bilhões em perdas com furtos**, e **53% do crescimento** veio de entregas onde clientes reportam itens ausentes — um vetor difícil de rastrear sem dados estruturados.



1.502 pedidos afetados em 10.000 analisados

Como o sistema funciona

Pipeline end-to-end, da ingestão de dados brutos ao score de risco.



Por que ML não supervisionado?

Sem rótulos históricos de fraude confirmada, a abordagem supervisionada não é viável. As três decisões centrais:

Isolation Forest para anomalias

Isola instâncias raras com menos splits — ideal quando fraude não é a maioria. Dispensa labels. Contaminação estimada em 10%.

K-Means (5 clusters) + DBSCAN

K-Means define perfis de risco com grupos fixos; DBSCAN encontra clusters de densidade. Estratégias complementares de segmentação.

Risk Score multi-fator (0–100)

Missing rate **25%**, anomaly score **25%**, padrão histórico **20%**, cluster risk **15%** e frequência **15%** — pesos calibrados para entregas.

O sistema em números

PEDIDOS ANALISADOS

10.000

Central Florida, ano completo de 2023

TAXA MISSING ITEMS

15%

1.502 pedidos com itens ausentes

EXPOSIÇÃO ESTIMADA

\$517K

Soma dos 1.502 pedidos afetados

MAIOR RISCO — MOTORISTA


6,1x

7,46% dos itens ausentes vs. média de 1,22%

Base de 1.247 motoristas e 1.239 clientes em 7 cidades da Flórida Central, jan a dez de 2023


Padrões por região

Taxa de pedidos com itens ausentes por cidade.



Insight: Altamonte Springs lidera com 16,2%, 1,2 p.p. acima da média regional de 15%. A variação entre cidades aponta fatores operacionais locais, além do comportamento individual.

O dashboard em produção



- Overview e Monitor com alertas em tempo real
- Geographic e Product Analysis por cidade

- Drivers e Customers com perfis de risco
- MLflow tracking e Drift Detection integrados

Anomalias são padrões que ainda não têm nome.

Em fraude logística, você priorizaria Recall ou Precision?

Me conta nos comentários 🙋

REPOSITÓRIO ABERTO

github.com/Another/walmart-delivery-fraud-detection

Leonardo

Data Science & Machine Learning

#DataScience

#MachineLearning

#Python